

Prédiction de Données et Biostatistiques

JOHANNES KEPLER UNIVERSITÄT



Autriche - Linz

BUT 2 Science des Données



2025



Etudiant : Rémi Pierron

Tuteur Professionnel : Andreas Futschik

Tuteur Pédagogique : Irina Belim

Remerciements

Je tiens à remercier le professeur **Andreas Futschik**, mon tuteur professionnel, et le professeur **Werner Müller**, responsable du département de statistiques appliquées à la **Johannes Kepler Universität de Linz**, pour leur accueil chaleureux et leur accompagnement durant mon stage.

Un grand merci également au professeur **Abdellah Qannari**, enseignant-chercheur à l'université de Poitiers, pour son aide précieuse sur mon projet de prévision de données.

Je remercie aussi le professeur **Laurent Bureau**, responsable du département Science des Données, pour son soutien dans la recherche de stage et les démarches administratives.

Enfin, je remercie ma tutrice pédagogique, la professeure **Irina Belim**, pour son suivi et ses conseils tout au long de cette expérience.

Avant-propos

Lorsque j'ai commencé mes études en BUT Science des Données, j'avais un objectif en tête : effectuer un stage à l'étranger. J'ai toujours accordé une grande importance à l'ouverture culturelle et au fait de sortir de mon cadre habituel. Réaliser une expérience professionnelle à l'international me semblait être une opportunité unique pour combiner apprentissage académique, enrichissement personnel et découverte d'un nouveau mode de vie.

Ce stage à la Johannes Kepler Universität de Linz, en Autriche, a été bien plus qu'une simple étape dans mon cursus : il a marqué un tournant dans mon parcours. Travailler au sein d'un département de statistiques reconnu, m'intégrer dans un environnement multiculturel et vivre au quotidien dans une ville que je ne connaissais pas m'ont permis de développer mon autonomie, mon adaptabilité, et de mieux comprendre la diversité des approches scientifiques à travers l'Europe.

Ce rapport témoigne de l'ensemble des apprentissages que j'ai pu tirer de cette expérience, tant sur le plan technique que personnel. Il reflète également la réalisation d'un projet qui me tenait à cœur depuis le début de mes études.

SOMMAIRE

<i>Présentation de l'organisme d'accueil</i>	3
I Johannes Kepler Universität Linz.....	3
II Le département des statistiques.....	4
III Mon intégration dans la structure d'accueil	4
<i>Description des missions</i>	5
I Première mission.....	5
II Seconde mission.....	6
<i>Projet principal 1 : prédiction des consommations d'électricité de la Linz AG</i>	7
I Contexte et objectifs du projet.....	7
II Préparation des données.....	8
III Analyse exploratoire.....	8
IV Modélisation	11
V Conclusion.....	18
<i>Projet principal 2 : étude biostatistique sur l'évolution de l'ADN des levures</i>	19
I Introduction	19
II Compréhension du projet.....	20
III Mon travail.....	21
IV Conclusion	21
<i>Activités secondaires</i>	24
I Immersion dans des cours de licence et de master en allemand et en anglais	24
II Séminaire	24
III Apports linguistiques et culturels.....	25
<i>Bilan du stage</i>	26
I Bilan Professionnel	26
II Bilan Personnel.....	27
III Conclusion Finale	27
<i>Glossaire</i>	28
<i>Annexe</i>	29

Présentation de l'organisme d'accueil

I – Johannes Kepler Universität Linz



Figure 1 Abords du lac de la JKU

Située en Haute-Autriche, la **Johannes Kepler Universität Linz (JKU)** est une université publique moderne et dynamique, fondée en 1966. Elle porte le nom du célèbre astronome et mathématicien Johannes Kepler, qui a vécu à Linz au XVII^e siècle. L'université est aujourd'hui reconnue pour son excellence académique, sa recherche interdisciplinaire et son ouverture à l'international.

Le campus principal, situé au nord de Linz, offre un cadre d'études agréable et verdoyant. Il regroupe les quatre facultés principales : **la faculté de sciences sociales, économiques et juridiques, la faculté de droit, la faculté de médecine et la faculté des sciences de l'ingénieur et des sciences naturelles**. Depuis quelques années, l'université a également développé une **School of Education** ainsi qu'un **Institute of Digital Sciences Austria (IDSA)**, tourné vers les technologies numériques et l'intelligence artificielle.

La JKU offre un environnement stimulant pour les stages, les projets de recherche et les échanges universitaires. Le département de **statistiques et de data science**, au sein duquel s'inscrit mon stage, joue un rôle central dans la formation à l'analyse de données appliquée, tant sur le plan théorique que pratique.



Figure 2 Abords du lac de la JKU



Figure 3 Forêt proche de Science Park

II – Le département des statistiques



Figure 4 JKU Science Park

Le département des statistiques appliqués se trouve dans le bâtiment Science Park 2 de la JKU.

Il est composé de trois professeurs d'université, quatre secrétaires, neuf collaborateurs scientifiques, cinq doctorants et sept collaborateurs étudiants.

L'Institut de Statistique Appliquée de la JKU de Linz propose une offre de formation complète dans le domaine de la statistique et de la science des données. Le **Bachelor Statistik und Data Science**, enseigné en allemand, forme les étudiants aux bases de la collecte,

l'analyse et la visualisation de données. Le **Master in Statistics and Data Science**, dispensé en anglais, permet un approfondissement des méthodes statistiques. Enfin, l'Institut propose un **programme doctoral** pour ceux souhaitant s'orienter vers la recherche en statistique appliquée. Ces formations allient théorie, pratique et ouverture internationale.

III – Mon intégration dans la structure d'accueil

Mon intégration dans l'université s'est faite par différents moyens. J'ai pu rencontrer quelques étudiants de Master en travaillant occasionnellement dans la même salle qu'eux. Mais j'ai surtout passé plus de temps à déjeuner avec les étudiants doctorants, les professeurs et les assistants.

J'ai aussi eu l'occasion de visiter un jardin botanique à Linz avec mon tuteur, et d'autres membres du département. Nous sommes ensuite allés dans un restaurant typique de Linz où j'ai pu découvrir les Wiener Schnitzel et la soupe d'asperges. Cela participe à la fois à mon intégration avec mes collègues et aussi à ma découverte de la culture autrichienne.



Figure 5 Visite du jardin botanique

Résumé de mes deux missions principales (Français)

Au cours de mon stage au sein du département de statistiques de la Johannes Kepler Universität de Linz, j'ai eu l'opportunité de travailler sur deux projets principaux, à la fois complémentaires et formateurs.

I - Prédiction de la consommation d'électricité de la Linz AG

Ce projet s'inscrivait dans le cadre du concours *Linz AG* Prognosechallenge 2024/2025*, dont l'objectif était de concevoir un modèle de prévision de la consommation électrique à court terme. Après avoir fusionné des données de consommation (toutes les 15 minutes) avec des données météorologiques issues de plusieurs localités, j'ai mené une analyse exploratoire approfondie pour identifier les effets saisonniers, journaliers et hebdomadaires sur la demande en électricité.

La modélisation a d'abord reposé sur des régressions linéaires multiples, puis s'est orientée vers des approches de machine learning plus performantes : **Random Forest*** et **XGBoost***. Ces méthodes ont permis d'atteindre un **R^2 * supérieur à 0.85** lors des prédictions sur données futures. Le projet m'a permis de mettre en œuvre des compétences avancées en data science, à la fois en R et en Python, et d'aborder des enjeux concrets liés à la transition énergétique.

II - Étude bio-statistique sur l'évolution de l'ADN des levures

Dans un second temps, j'ai participé à la reproduction des résultats graphiques d'une étude scientifique publiée en 2021 (*Phillips et al.*), portant sur l'évolution génétique de populations synthétiques de levures. L'objectif était de comparer deux méthodes de croisement (aléatoire et structuré) en termes de conservation de la diversité génétique au fil des générations.

Après avoir étudié l'article en détail, j'ai développé, en langage R, des scripts permettant de visualiser les **fréquences alléliques*** à différents cycles de reproduction. Ce travail m'a permis de renforcer mes compétences en biostatistiques, en analyse de données génétiques, et en communication scientifique.

Summary of My Two Main Projects

During my internship at the Department of Statistics at Johannes Kepler University Linz, I had the opportunity to work on two major and complementary projects, which allowed me to apply and further develop my skills in data science and statistical analysis.

1 - Electricity Consumption Forecasting for Linz AG

This project was part of the *Linz AG Prognosechallenge 2024/2025*, which aimed to develop a short-term electricity consumption forecasting model. I first merged high-frequency electricity consumption data (15-minute intervals) with meteorological data from multiple locations in Upper Austria. A thorough exploratory analysis helped identify seasonal, weekly, and daily patterns in energy demand.

The modeling phase started with multiple linear regression and progressed to more advanced machine learning approaches, including **Random Forest** and **XGBoost**. These models achieved high predictive performance, with **R² values above 0.85** when tested on future data. This project allowed me to apply a wide range of data science techniques using both R and Python, while deepening my understanding of energy-related forecasting challenges.

2 - Biostatistical Study on Yeast DNA Evolution

My second assignment involved reproducing graphical results from a scientific paper published in 2021 (*Phillips et al.*), which investigated how different crossing strategies affect genetic diversity in synthetic yeast populations. The study compared two methods: a simple mixing approach and a more structured pairwise crossing strategy.

After analyzing the study in detail, I wrote R scripts to recreate key visualizations, such as allele frequency spectra across several evolutionary cycles. This work strengthened my skills in biostatistics, data visualization, and interpretation of genetic data in a controlled experimental context.

Premier projet : prédictions de la consommation d'électricité de la Linz AG

I – Contexte et objectifs du projet

Dans le cadre de la « Linz AG Prognosechallenge 24/25 », le défi consiste à développer un modèle de prévision de la consommation électrique à court terme. Ce projet s'inscrit dans un contexte énergétique où la précision des prévisions est essentielle pour maintenir l'équilibre entre la production et la consommation d'électricité. En effet, un écart entre la consommation anticipée et la consommation réelle peut engendrer des coûts supplémentaires importants, notamment à travers des mesures de redispatching.

La consommation d'électricité est mesurée et facturée par tranches de 15 minutes, et elle dépend fortement de facteurs temporels comme le jour de la semaine, les jours fériés ou la saison. Avec l'essor des installations photovoltaïques (PV) et des pompes à chaleur, cette consommation est devenue encore plus sensible aux conditions météorologiques, ce qui ajoute un degré de complexité aux prévisions. Par ailleurs, la nature non stationnaire du processus liée à l'évolution du comportement des consommateurs clientèle complique davantage la tâche.

Les données mises à disposition couvrent la période du 1er janvier 2021 au 1er mai 2024 pour la consommation électrique, et jusqu'au 1er novembre 2024 pour les données météorologiques et les profils de charge standard (SLP). Ces derniers, qui décrivent les courbes typiques de consommation pour différents types d'utilisateurs (ménages, entreprises, etc.), peuvent être utilisés pour améliorer les prédictions. Les variables météorologiques concernent six localités de Haute-Autriche, et incluent notamment la température, le rayonnement solaire, la vitesse du vent et les précipitations.

L'objectif final est de prédire avec précision la consommation d'électricité entre le 1er mai et le 1er novembre 2024, en utilisant toutes les sources de données disponibles. Les performances des modèles seront évaluées à l'aide du coefficient de détermination R^2 .

II – Préparation des données

La phase de préparation des données constitue une étape cruciale du projet, visant à structurer et à enrichir les informations brutes pour les rendre exploitables dans un cadre de modélisation statistique. Deux jeux de données sont d'abord importés : la consommation électrique agrégée (*gesamtabsatz*) mesurée toutes les 15 minutes, et les données météorologiques issues de six localités. Une jointure est ensuite réalisée sur la base du timestamp afin d'obtenir un jeu de données combiné.

Les données météorologiques sont initialement structurées par ville et par variable (ex. *temp_Linz*, *temp_Gramastetten*). Afin de réduire la dimensionnalité tout en conservant l'information climatique globale, une moyenne est calculée pour chaque type de variable météorologique (température, vent, précipitations, etc.) sur l'ensemble des localités, pour chaque intervalle de temps. Cela permet d'obtenir une table finale (*data_avg*) contenant, pour chaque pas de temps, la consommation électrique et les moyennes des différentes mesures météorologiques.

Cette table constitue la base des analyses ultérieures. Elle est nettoyée des valeurs manquantes, puis enrichie par des variables temporelles dérivées (comme la saison). Elle est également exportée dans un fichier CSV, garantissant sa réutilisabilité dans des phases ultérieures de modélisation ou d'analyse exploratoire.

III – Analyse exploratoire

L'analyse exploratoire constitue une étape fondamentale dans tout projet de modélisation prédictive. Dans le cadre de la *Linz AG Prognosechallenge 2024/2025*, cette phase a pour objectif d'identifier les structures saisonnières, hebdomadaires et journalières de la consommation électrique, ainsi que les facteurs météorologiques pouvant expliquer sa variabilité. Cette exploration repose sur deux jeux de données : la consommation d'électricité mesurée toutes les 15 minutes entre janvier 2021 et mai 2024, et les données météorologiques agrégées provenant de six localités de Haute-Autriche, couvrant la même période.

1. Exploration des données météorologiques moyennées

Une première étape a consisté à agréger les variables météorologiques par type (température, vent, rayonnement solaire, précipitations) en calculant leur moyenne sur l'ensemble des localités. Cette simplification permet de réduire la complexité du jeu de données tout en conservant l'information climatique globale pertinente pour la prévision à l'échelle régionale.

Afin d'évaluer l'influence de chaque variable météorologique sur la consommation électrique (gesamtabsatz), des régressions linéaires simples ont été effectuées, chacune prenant comme prédicteur une moyenne météorologique. Les résultats indiquent que la température moyenne est la variable la plus corrélée à la consommation, avec un coefficient de détermination R^2 de 0.111. La vitesse du vent suit ($R^2 = 0.053$), ainsi que le rayonnement solaire direct ($R^2 = 0.031$). En revanche, les précipitations ne présentent pratiquement aucun pouvoir explicatif ($R^2 < 0.001$). Ces résultats, bien que modestes, confirment que les conditions météorologiques influencent la demande en énergie, notamment pour les besoins de chauffage ou de climatisation, mais qu'elles ne suffisent pas à modéliser à elles seules la complexité du phénomène.

2. Statistiques descriptives et saisonnalité

Les statistiques descriptives de la variable gesamtabsatz montrent une consommation moyenne de 122,5 MW, avec un écart-type de 30,13 MW. La distribution est relativement étendue, avec un premier quartile à 99 MW, une médiane à 119,3 MW, et un troisième quartile à 143,3 MW. L'analyse mensuelle révèle une nette saisonnalité : les valeurs les plus élevées sont enregistrées en hiver (145 MW en décembre, 144 MW en janvier), tandis que les consommations sont plus faibles durant la période estivale (autour de 106 MW en juin, juillet et août). Ces résultats traduisent des besoins énergétiques accrus pour le chauffage en hiver, tendance classique dans les pays européens à climat continental.




Figure 6 Boîtes à moustaches

Cette saisonnalité est également visible dans les diagrammes en boîte (boxplots), qui mettent en évidence une variabilité plus faible durant l'été, ainsi qu'une concentration des fortes consommations en hiver. Une décomposition de la série chronologique quotidienne selon un modèle additif confirme la présence d'une composante saisonnière importante, ainsi que d'une tendance légèrement décroissante sur la période étudiée. Cette observation peut s'expliquer par des gains d'efficacité énergétique ou une croissance de la production photovoltaïque qui amortit la consommation nette.

3. Effets hebdomadaires et journaliers




Figure 7 Boîtes à moustaches

La consommation électrique présente également des régularités hebdomadaires. En moyenne, elle atteint son maximum les mardis et mercredis (≈ 130 MW) et diminue significativement le week-end, avec un minimum observé le dimanche (≈ 107 MW). Ce profil est cohérent avec les rythmes d'activité industrielle et tertiaire, plus intenses en semaine.

Les effets journaliers sont encore plus marqués. En agrégeant la consommation par heure de la journée, on observe une courbe typique en forme de double bosse : après un minimum autour de 3 heures du matin (≈ 91 MW), la consommation croît fortement pour atteindre un pic à 7h-8h (≈ 140 MW), avant de redescendre légèrement en journée, puis de remonter légèrement en début de soirée. Cette structure reflète les cycles d'activité humaine, marqués par le démarrage de la journée de travail, les périodes de chauffage ou de climatisation, et la présence des occupants dans les logements.




Figure 8 Journée typique en termes de conso. électrique

Les corrélations statistiques confirment ces observations. La corrélation de Pearson entre l'heure et la consommation est estimée à 0.279 ($p < 2.2e-16$), tandis que la corrélation de Spearman, plus robuste aux non-linéarités, atteint 0.306. Ces valeurs suggèrent une relation monotone significative entre les deux variables, avec un effet journalier structurant.

Conclusion de l'analyse exploratoire

L'analyse exploratoire a mis en évidence une influence modérée de la température moyenne sur la consommation d'électricité, tandis que les autres variables météorologiques, comme le vent, le rayonnement solaire et les précipitations, ont un impact plus limité. La consommation présente une forte saisonnalité, avec des pics en hiver et une plus grande stabilité en été, ainsi que des variations hebdomadaires et journalières liées aux rythmes d'activité.

Ces observations soulignent l'intérêt d'utiliser une régression linéaire multiple pour modéliser la consommation en intégrant à la fois les facteurs météorologiques et temporels, afin d'améliorer la précision des prédictions.

IV – Modélisation

1. RLM avec les données météorologiques

Notre première étape pour construire un modèle de prédiction de la consommation d'électricité repose sur une Régression Linéaire Multiple (RLM) utilisant uniquement des variables météorologiques moyennes journalières. Le modèle est ajusté selon la formule suivante :

```
modele <- lm(gesamtabsatz ~ dhi_mean + dni_mean + ghi_mean +  
              precipitation_mean + temp_mean + windspeed_mean,  
              data = data)
```

Figure 9 Modèle de RLM avec R

Le modèle est globalement significatif ($F = 5185$, $p < 2.2e-16$) avec un R^2 ajusté de 0,21, ce qui signifie que 21 % de la variabilité de la consommation est expliquée par les variables incluses.

Pour améliorer notre modèle, nous allons rajouter les variables temporelles catégorielles.

2. RLM avec les données météorologiques ET temporelles

Afin d'améliorer le pouvoir explicatif du modèle, nous avons enrichi la Régression Linéaire Multiple précédente en y intégrant des **variables temporelles** : l'heure, le jour de la semaine et le mois. Le modèle est défini comme suit :

```
modele <- lm(gesamtabatz ~ dhi_mean + dni_mean + ghi_mean +  
             temp_mean + windspeed_mean +  
             heure + jour_semaine + mois,  
             data = data)
```

Figure 10 Modèle de RLM avec R

Le modèle affiche un **R² ajusté de 0,4461**, ce qui signifie que **près de 45 % de la variabilité** de la consommation d'électricité est expliquée par les variables météorologiques et temporelles combinées. C'est une amélioration significative par rapport au modèle basé uniquement sur la météo ($R^2 \approx 21\%$).




Figure 11 Données prédites avec la RLM sur R

Cependant, la précision des prédictions n'est toujours pas suffisante, même en utilisant toutes les variables à notre disposition. La RLM atteint ses limites et nous devons considérer une méthode plus avancée pour parvenir à de meilleurs résultats. Et cette méthode, c'est le **Machine Learning**.

3. When in doubt, use Random Forest !

Une **Random Forest** (ou forêt aléatoire) est un **algorithme d'apprentissage automatique supervisé** utilisé à la fois pour la **classification** et la **régression**. C'est une méthode d'ensemble qui **combine plusieurs arbres de décision** entraînés sur des sous-échantillons différents des données, en introduisant de l'aléa dans le choix des variables à chaque division de l'arbre. Le but est de **réduire le surapprentissage** et d'**améliorer la précision** du modèle.

L'étape initiale consiste à entraîner le modèle sur l'ensemble des données. Le R^2 entre les données réelles et prédites est de 0.98, ce qui montre que notre modèle reproduit « virtuellement » la réalité. Nous pouvons donc modéliser la prédiction d'électricité future avec ce modèle, en se basant toujours sur les variables catégorielles temporelles et sur les prévisions météorologiques.




Figure 12 Données prédites avec Random Forest sur R

Afin de valider la qualité de ces prédictions, nous devons effectuer quelques tests supplémentaires.

L'expérience que l'on mène est la suivante : nous entraînons le modèle sur les données de 2021, puis nous produisons les prédictions pour 2022 et nous comparons avec les données réelles. On répète la même chose en entraînant sur 2022 et en prédisant 2023, puis on entraîne sur 2021 et 2022 pour prédire 2023. À chaque itération de cette expérience, le R^2 est supérieur à 0.86 entre les données réelles et prédites, ce qui signifie que le modèle a un pouvoir explicatif supérieur à 86%.




Figure 13 Expérience de comparaisons entre données réelles et prédites




Figure 14 Expérience de comparaison entre données réelles et prédites (zoom)

4. Peut-on faire mieux avec XGBoost ?

Une alternative à Random Forest existe, et il s'agit de XGBoost. C'est un modèle de machine learning plus complexe à paramétrer mais potentiellement plus précis.

Optimisation automatique d'un modèle XGBoost

Afin de trouver les paramètres les plus optimaux pour notre modèle, nous utilisons un algorithme qui permet de les déterminer automatiquement.

Pour cela, une méthode de **recherche aléatoire d'hyperparamètres** est utilisée, via le package caret. Cette méthode consiste à tester un certain nombre de combinaisons de paramètres choisis au hasard, puis à évaluer chaque modèle par validation croisée.

Une fois les meilleurs paramètres identifiés, le modèle final est entraîné sur l'ensemble des données fournies. Sa performance est ensuite mesurée à l'aide du coefficient de détermination R^2 , qui permet d'évaluer la qualité des prédictions.

Le R^2 sur les données d'entraînement est de plus de **0.98**, comme pour Random Forest.

Les paramètres idéaux déterminés par l'algorithme sont les suivants :

```
modele_xgb <- xgboost(data = X_matrix, label = y,  
                      nrounds = 844, max_depth = 8, eta = 0.378,  
                      gamma = 2.83, colsample_bytree = 0.648,  
                      min_child_weight = 5, subsample = 0.993,  
                      objective = "reg:squarederror", verbose = 0)
```

Figure 15 Modèle XGBoost avec paramètres optimaux sur R

Voici le détail de chaque paramètre afin de mieux comprendre leur importance :

nrounds = 844 : Nombre d'**itérations d'entraînement** (arbres successifs). Plus ce nombre est élevé, plus le modèle peut apprendre, mais au risque de surajuster.

max_depth = 8 : **Profondeur maximale** des arbres. Un arbre plus profond peut modéliser des relations complexes, mais augmente aussi le risque de surapprentissage.

eta = 0.378 : **Taux d'apprentissage** (learning rate). Il contrôle la vitesse à laquelle le modèle apprend. Une valeur modérée (comme ici) permet un bon équilibre entre rapidité et précision.

gamma = 2.83 : **Seuil de gain** pour faire une nouvelle division (split). Plus il est élevé, plus le modèle est régularisé (il évite les divisions peu utiles). Cela aide à limiter la complexité.

colsample_bytree = 0.648 : Fraction de **colonnes (variables)** utilisées pour chaque arbre. Ici, environ 65 % des variables sont utilisées, ce qui favorise la diversité entre les arbres.

min_child_weight = 5 : **Poids minimum d'un nœud** pour pouvoir le diviser. Cela évite que le modèle ne crée des branches sur des sous-échantillons trop petits (limite le surapprentissage).

subsample = 0.993 : **Fraction d'exemples** utilisés pour entraîner chaque arbre. Ici, presque toutes les données sont utilisées à chaque arbre, ce qui favorise la stabilité.

objective = "reg:squarederror" : Fonction objectif pour la **régression** : l'erreur quadratique moyenne. C'est l'objectif standard pour les prédictions numériques.

Ces paramètres permettent de construire un **modèle puissant, mais régularisé**. Ils assurent un bon compromis entre complexité, performance et généralisation, en évitant que le modèle ne s'adapte trop fortement aux données d'entraînement (ce qu'on appelle le **surapprentissage**).

Python, un langage plus rapide que R pour le Machine Learning

Afin de produire les nouvelles prédictions nous allons utiliser Python, car les bibliothèques de Machine Learning sont, d'après plusieurs sources, plus optimisées que celles de R. C'est donc l'occasion d'essayer un autre langage pour plus de diversité dans ce projet.

Avec Python, le programme de prédiction XGBoost s'exécute pratiquement instantanément. Nous conservons les paramètres déterminés précédemment, puis nous répétons l'expérience que nous avons menée avec Random Forest, qui consiste à mener des tests en entraînant le modèle sur une année puis à réaliser les prédictions sur la suivante pour les comparer aux valeurs réelles.

```
# Modèle avec paramètres fixes
fixed_model = XGBRegressor(
    objective="reg:squarederror",
    n_estimators=844,
    max_depth=8,
    learning_rate=0.378,
    gamma=2.83,
    colsample_bytree=0.648,
    min_child_weight=5,
    subsample=0.993,
    verbosity=0
)
```

Figure 16 Modèle XGBoost avec paramètres optimaux sur Python




Figure 17 Comparaison entre valeur réelles et prédites




Figure 18 Comparaison entre valeur réelles et prédites (zoom)

Les résultats de cette expérience sont excellents : nous obtenons des R^2 qui oscillent entre 0.84 et 0.85 entre les prédictions et les données d'entraînement.

V – Conclusion

Ce projet m'a permis de mettre en pratique l'ensemble des compétences acquises au cours de ma formation, en particulier en traitement de données, en analyse exploratoire et en modélisation prédictive. À partir d'un jeu de données riche mais complexe, j'ai su extraire des informations pertinentes, identifier les principaux facteurs explicatifs de la consommation d'électricité, et tester différentes approches de modélisation, allant de la régression linéaire à des méthodes plus avancées comme la Random Forest et XGBoost.

Parmi les modèles testés, la Random Forest s'est révélée la plus robuste pour prédire la consommation électrique de la Linz AG, avec un R^2 supérieur à 0.86 en généralisation.

Au-delà de l'aspect technique, ce projet m'a également sensibilisé à l'importance des données météorologiques et temporelles dans les systèmes énergétiques, ainsi qu'aux enjeux industriels associés à la prévision de la demande. Il constitue une étape significative dans mon parcours vers un métier de Data Scientist.

Second projet : étude bio-statistique sur l'évolution de l'ADN des levures

I - Introduction

Dans le cadre de ma seconde mission au sein du département de statistiques de la JKU, j'ai été chargé de reproduire et d'interpréter les résultats graphiques issus de l'étude scientifique "Crossing design shapes patterns of genetic variation in synthetic recombinant populations of *Saccharomyces cerevisiae*" publiée en 2021 par Phillips et al. Cette étude explore comment différentes stratégies de croisement influencent la diversité génétique au sein de populations recombinantes synthétiques de levures.

Les chercheurs y comparent deux méthodes de construction de populations de levures génétiquement variables : une méthode simple de mélange ("K-type") et une méthode plus structurée impliquant des croisements par paires ("S-type"). L'objectif principal est de déterminer laquelle de ces méthodes permet de maximiser la variation génétique initiale et sa stabilité au cours du temps, critère fondamental dans le cadre d'expériences d'évolution expérimentale (Evolve and Resequence, ou E&R).

Mon travail a consisté à reproduire les graphiques clés de cette étude, notamment les spectres de fréquence des SNP, les niveaux d'hétérozygotie et de diversité haplotypique, ainsi que les signatures de sélection potentielle au fil des cycles de reproduction. Ces visualisations sont accompagnées d'une explication synthétique du protocole expérimental, des indicateurs utilisés, et de leur intérêt pour l'analyse de l'évolution génétique dans un contexte contrôlé.

Au moment de la rédaction de ce rapport, ce projet n'est pas terminé. Voici mon avancée la plus récente !

II - Compréhension et résumé de l'étude

Les chercheurs se sont intéressés à la façon dont on construit des populations de levures (*Saccharomyces cerevisiae*) pour étudier leur évolution en laboratoire. Pour que ces expériences soient fiables, il faut que ces populations contiennent une bonne diversité génétique dès le départ.

Ils ont comparé deux méthodes pour mélanger les souches de levure :

- Une méthode simple où l'on **mélange toutes les souches d'un coup** (appelée méthode K).
- Une méthode plus soignée où l'on **fait des croisements deux par deux** (méthode S), comme un mariage organisé entre souches.

Ils ont testé ces deux méthodes avec 4, 8 ou 12 souches différentes, et ont fait évoluer les populations pendant plusieurs cycles de reproduction.

Ce qu'ils ont découvert :

- La **méthode soignée (S)** donne des populations **plus riches en diversité génétique** et avec une **meilleure répartition des souches**.
- La **méthode simple (K)**, surtout avec beaucoup de souches (12), donne des populations **déséquilibrées**, où certaines souches disparaissent presque complètement.
- Ces différences sont visibles dès le début, probablement parce que certaines souches se reproduisent mieux que d'autres.
- Les chercheurs ont aussi vu des signes que **certaines régions du génome changent plus que d'autres**, ce qui pourrait indiquer une forme d'adaptation à la reproduction sexuée imposée.
- En revanche, les **caractéristiques comme la vitesse de croissance ou la capacité à se reproduire** n'ont pas beaucoup changé, sauf dans un cas extrême (K12).

Conclusion :

Si on veut observer l'évolution de levures en laboratoire, **mieux vaut prendre le temps de faire les croisements de manière organisée**. Cela permet d'avoir des populations plus équilibrées, plus diversifiées et donc plus intéressantes pour étudier l'évolution.

III - Mon travail

Après avoir passé du temps à essayer de comprendre les grandes lignes de l'étude statistique, j'ai tenté de reproduire certains graphiques avec le langage R.

Les voici, ainsi que le code qui permet de les générer :




Figure 19 Répartition des freq alléliques avec pop de taille 4




Figure 20 Répartition des freq alléliques avec pop de taille 8




Figure 21 Répartition des freq alléliques avec pop de taille 12

Explication du code R :

```
1 setwd("/Users/remierron/Library/CloudStorage/OneDrive-UniversitéPoitiers/biostats/dat
2
3
4 # ----- Fonctions -----
5
6 extract_frequencies <- function(df) {
7   freqs_raw <- strsplit(df$founderfreqs, ";")
8   freqs <- as.numeric(unlist(freqs_raw))
9   return(pmax(0, pmin(1, freqs)))
10 }
11
12 plot_snp_spectrum <- function(freqs, title, col = "steelblue") {
13   hist(freqs,
14     breaks = seq(0, 1, length.out = 41),
15     col = col,
16     include.lowest = TRUE,
17     main = title,
18     xlab = "Founder Allele Frequency",
19     ylab = "Counts",
20     border = "white")
21 }
22
23 # ----- Paramètres -----
24
25 types <- c("S", "K")
26 cycles <- c("0", "6", "12")
27 colors <- list("S" = "Forestgreen", "K" = "Firebrick")
28
29 # ----- Séparé par taille de fondation -----
30
31 for (size in c(4, 8, 12)) {
32   output_file <- paste0("SFS_founder", size, ".png")
33   png(output_file, width = 1000, height = 1200)
34   par(mfrow = c(2, 3), mar = c(4, 4, 2, 1)) # 2 types x 3 temps
35
36   for (type in types) {
37     for (cycle in cycles) {
38       label <- paste0(type, size, " ", cycle)
39       filename <- paste0(size, tolower(type), "_haps_", cycle, ".txt")
40
41       if (file.exists(filename)) {
42         df <- read.table(filename, header = TRUE, sep = "\t", stringsAsFactors = FALSE)
43         freqs <- extract_frequencies(df)
44         plot_snp_spectrum(freqs, title = label, col = colors[[type]])
45       } else {
46         plot.new()
47         title(main = paste("Missing:", label))
48       }
49     }
50   }
51
52   dev.off()
53   cat("Image générée :", output_file, "\n")
54 }
55
56 }
```

Figure 22 Code R des biostats

Ce script R permet de générer des graphiques représentant la répartition des fréquences alléliques chez les individus fondateurs (SFS : *Site Frequency Spectrum*), pour différentes tailles de population (4, 8 et 12 individus), à trois moments de l'évolution (cycles 0, 6 et 12), et selon deux types de traitements (S et K).

Deux fonctions sont utilisées : la première (`extract_frequencies`) extrait les fréquences alléliques à partir des fichiers, la seconde (`plot_snp_spectrum`) trace un histogramme des fréquences.

Les fichiers de données de données sont au format txt et ont une structure très difficile à exploiter. Un exemple se trouve en annexe.

Pour chaque taille de population, le script crée une image PNG contenant 6 graphiques (2 types × 3 temps). Il lit les fichiers de données correspondant à chaque combinaison, extrait les fréquences, puis trace l'histogramme avec une couleur spécifique selon le type. Si un fichier est manquant, un graphique vide est affiché avec la mention "Missing".

Ces figures permettent de visualiser comment les allèles sont répartis chez les fondateurs, et de comparer cette distribution entre les différentes conditions expérimentales.

IV - Conclusion du second projet

Ce second projet m'a permis de découvrir une application concrète des statistiques dans le domaine de la génétique évolutive. En travaillant sur la reproduction des résultats de l'étude de *Phillips et al. (2021)*, j'ai non seulement approfondi ma compréhension des notions de diversité génétique, de fréquence allélique et de sélection, mais j'ai également développé une plus grande autonomie dans l'interprétation d'articles scientifiques complexes en anglais.

La réalisation des visualisations avec le langage R m'a confronté à des jeux de données biologiques réels et parfois imparfaits, nécessitant une attention particulière dans le traitement, la structuration et la représentation des données. Ce travail m'a aussi sensibilisé à l'importance des choix expérimentaux en biologie (notamment les méthodes de croisement) sur les résultats obtenus.

Activités secondaires

I - Immersion dans des cours de licence et de master en allemand et en anglais

Dans le cadre de mon stage, j'ai eu l'opportunité d'assister à plusieurs cours proposés à la JKU, en licence (allemand) et en master (anglais). J'ai initialement tenté de suivre un cours de programmation en R dispensé en allemand, mais j'ai rapidement abandonné cette piste, car le niveau de langue requis dépassait mes compétences actuelles, rendant la compréhension difficile.

En revanche, j'ai assisté à des cours de master donnés en anglais, notamment en **experimental design** et en **statistiques**. Bien que ces cours aient été intéressants sur le fond, leur suivi s'est avéré exigeant car j'y ai été intégré en cours de semestre. J'ai pu saisir les grandes lignes des contenus abordés, mais il m'a été difficile de tout assimiler, en particulier les notions théoriques plus poussées abordées sans introduction préalable.

II - Séminaire

J'ai également assisté à un séminaire scientifique présenté par **Corinna Perchtold**, doctorante au sein du département, intitulé *Spatio-temporal Precipitation Modeling in Austria*. Cette présentation portait sur la modélisation des précipitations en Autriche à l'aide de **modèles additifs généralisés spatio-temporels**, dans une perspective d'évolution climatique. Trois scénarios ont été analysés : la moyenne mensuelle des précipitations, les précipitations mensuelles maximales, et la durée maximale de sécheresse par mois. Chacun était modélisé à l'aide de distributions statistiques adaptées (gamma, GEV mixte, binomiale négative). Le séminaire se terminait sur une ouverture vers la modélisation de la mortalité, illustrant ainsi la diversité des applications des statistiques spatiales.

Ce moment m'a permis d'élargir ma culture scientifique et de découvrir un domaine encore peu abordé dans ma formation.

III - Apports linguistiques et culturels

Sur le plan linguistique, ce stage a grandement contribué à renforcer ma pratique de l'**anglais**, que ce soit à travers les échanges quotidiens avec mes collègues, la participation aux cours, ou la lecture d'articles scientifiques. Mon aisance à l'oral comme à l'écrit s'est nettement améliorée.

Sur le plan culturel, j'ai eu la chance de découvrir plusieurs villes d'Autriche (Linz, Vienne, Steyr, Strobl, ...). Ces moments ont facilité mon intégration tout en m'offrant une immersion authentique dans la culture autrichienne.



Figure 23 Point de vue à Steyr




Figure 24 Point de vue dans les montagnes



Figure 26 Cathédrale de Vienne



Figure 25 Jardin botanique de Linz

Bilan final

I - Bilan professionnel

Ce stage au sein du département de statistiques de la Johannes Kepler Universität de Linz a été une expérience professionnelle particulièrement formatrice. Il m'a permis de renforcer mes compétences techniques en science des données, mais aussi d'en acquérir de nouvelles, notamment en **machine learning**, un domaine que je connaissais peu auparavant. J'ai ainsi appris à utiliser par moi-même des méthodes avancées comme **Random Forest** ou **XGBoost**, en explorant leur logique, leurs paramètres, et leurs performances, aussi bien en R qu'en Python.

Le premier projet, axé sur la prévision de la consommation électrique, m'a particulièrement motivé. Il m'a permis de mettre en œuvre un raisonnement analytique complet, depuis la préparation des données jusqu'à la mise en place d'un modèle prédictif robuste. Ce travail a renforcé mon intérêt pour l'application concrète de la data science à des enjeux énergétiques, et m'a donné **envie de poursuivre mes études en master avec l'objectif de devenir data scientist**.

Le second projet, bien que non terminé, m'a permis de découvrir un autre champ d'application : les **biostatistiques**. J'ai appris à interpréter un article scientifique complexe et à reproduire certaines visualisations à l'aide de R. Si je suis encore loin d'en maîtriser tous les aspects, cette immersion m'a donné un aperçu stimulant des liens entre statistiques, biologie et génétique.

Enfin, la participation à des cours et séminaires, même partielle, m'a permis d'élargir mes connaissances dans des domaines variés, tout en m'exposant à un environnement académique international et exigeant.

II - Bilan personnel

Sur le plan personnel, ce stage m'a confronté à un **véritable défi linguistique**. Suivre des cours en anglais, échanger avec mes collègues ou comprendre un séminaire scientifique a nécessité un réel effort, surtout en début de stage. J'ai cependant persévéré pour **faire de mon mieux** et m'améliorer progressivement. Mon anglais, tant à l'oral qu'à l'écrit, s'en est trouvé considérablement renforcé.

Au-delà de l'aspect linguistique, ce séjour à l'étranger m'a permis de développer mon **autonomie**, mon **adaptabilité** et ma **curiosité culturelle**. J'ai eu la chance de découvrir plusieurs villes autrichiennes, d'échanger avec des étudiants internationaux et de partager des moments conviviaux avec mes collègues, renforçant ainsi mon ouverture d'esprit.

III - Conclusion Finale

En résumé, ce stage à la **Johannes Kepler Universität de Linz** a été une expérience complète, à la fois exigeante et enrichissante. Il m'a permis de développer des compétences techniques solides en data science, d'explorer de nouveaux domaines comme le **machine learning** et les **biostatistiques**, et de me confronter à un **environnement international** stimulant. Malgré certaines difficultés, notamment linguistiques, j'ai su m'adapter, progresser et tirer le meilleur de cette immersion.

Ce stage marque un tournant dans mon parcours : il a confirmé mon intérêt pour les problématiques de **modélisation prédictive** et renforcé ma motivation à poursuivre mes études en **master** pour devenir **Data Scientist**. C'est une étape déterminante qui m'a permis de gagner en assurance, en autonomie, et en clarté sur mon avenir professionnel.

Glossaire

Diversité haplotypique : mesure de la diversité génétique liée à l'ensemble des gènes hérités d'un seul parent.

Fréquences alléliques : La fréquence allélique est la proportion d'un allèle par rapport à l'ensemble des allèles d'un gène dans une population.

Hétérozygotie : mesure de la diversité génétique, correspondant à la présence d'allèles différents sur un locus.

Hyperparamètres : paramètres qui contrôlent le comportement d'un algorithme d'apprentissage automatique et qui sont fixés avant l'entraînement.

JKU : Johannes Kepler Universität

Linz AG : Entreprise qui gère l'électricité de Linz.

R² : indicateur mesurant le lien entre deux variables. Plus il est proche de 1, plus les deux variables sont liées.

Random Forest, XGBoost : Algorithmes de Machine Learning.

SNP (Single Nucleotide Polymorphism) : variation d'une seule base dans l'ADN entre individus.

Surapprentissage (overfitting) : lorsque le modèle apprend trop bien les données d'entraînement, au détriment de la généralisation.

Annexe

4k_haps_12.txt

poolroot	chr	pos	NSNPs	founder	names	cutree	number	leaves	founder	fregs	adifounder	fregs
alt_YEE_rec_4K_12	chr10	36600	297	A1;	A2;	B3;	B4	1;2;3;4	4	0.958;3e-04;0.0381;0.0036	0.958;3e-04;0.0381;0.0036	0.958;3e-04;0.0381;0.0036
alt_YEE_rec_4K_12	chr10	37600	309	A1;	A2;	B3;	B4	1;2;3;4	4	0.9595;3e-04;0.0365;0.0038	0.9595;3e-04;0.0365;0.0038	0.9595;3e-04;0.0365;0.0038
alt_YEE_rec_4K_12	chr10	38600	321	A1;	A2;	B3;	B4	1;2;3;4	4	0.961;3e-04;0.0347;0.0039	0.961;3e-04;0.0347;0.0039	0.961;3e-04;0.0347;0.0039
alt_YEE_rec_4K_12	chr10	39600	329	A1;	A2;	B3;	B4	1;2;3;4	4	0.9627;3e-04;0.0329;0.0041	0.9627;3e-04;0.0329;0.0041	0.9627;3e-04;0.0329;0.0041
alt_YEE_rec_4K_12	chr10	40600	337	A1;	A2;	B3;	B4	1;2;3;4	4	0.964;3e-04;0.0312;0.0045	0.964;3e-04;0.0312;0.0045	0.964;3e-04;0.0312;0.0045
alt_YEE_rec_4K_12	chr10	41600	350	A1;	A2;	B3;	B4	1;2;3;4	4	0.9649;3e-04;0.0299;0.0048	0.9649;3e-04;0.0299;0.0048	0.9649;3e-04;0.0299;0.0048
alt_YEE_rec_4K_12	chr10	42600	360	A1;	A2;	B3;	B4	1;2;3;4	4	0.9654;3e-04;0.029;0.0053	0.9654;3e-04;0.029;0.0053	0.9654;3e-04;0.029;0.0053
alt_YEE_rec_4K_12	chr10	43600	367	A1;	A2;	B3;	B4	1;2;3;4	4	0.9653;5e-04;0.0284;0.0058	0.9653;5e-04;0.0284;0.0058	0.9653;5e-04;0.0284;0.0058
alt_YEE_rec_4K_12	chr10	44600	377	A1;	A2;	B3;	B4	1;2;3;4	4	0.9648;0.0011;0.0278;0.0063	0.9648;0.0011;0.0278;0.0063	0.9648;0.0011;0.0278;0.0063
alt_YEE_rec_4K_12	chr10	45600	393	A1;	A2;	B3;	B4	1;2;3;4	4	0.9641;0.0016;0.0275;0.0068	0.9641;0.0016;0.0275;0.0068	0.9641;0.0016;0.0275;0.0068
alt_YEE_rec_4K_12	chr10	46600	403	A1;	A2;	B3;	B4	1;2;3;4	4	0.9631;0.0023;0.0274;0.0073	0.9631;0.0023;0.0274;0.0073	0.9631;0.0023;0.0274;0.0073
alt_YEE_rec_4K_12	chr10	47600	416	A1;	A2;	B3;	B4	1;2;3;4	4	0.9618;0.003;0.0275;0.0077	0.9618;0.003;0.0275;0.0077	0.9618;0.003;0.0275;0.0077
alt_YEE_rec_4K_12	chr10	48600	421	A1;	A2;	B3;	B4	1;2;3;4	4	0.9602;0.004;0.0278;0.008	0.9602;0.004;0.0278;0.008	0.9602;0.004;0.0278;0.008
alt_YEE_rec_4K_12	chr10	49600	428	A1;	A2;	B3;	B4	1;2;3;4	4	0.9584;0.0051;0.0284;0.0081	0.9584;0.0051;0.0284;0.0081	0.9584;0.0051;0.0284;0.0081
alt_YEE_rec_4K_12	chr10	50600	452	A1;	A2;	B3;	B4	1;2;3;4	4	0.9565;0.0063;0.0292;0.008	0.9565;0.0063;0.0292;0.008	0.9565;0.0063;0.0292;0.008
alt_YEE_rec_4K_12	chr10	51600	465	A1;	A2;	B3;	B4	1;2;3;4	4	0.9546;0.0074;0.0303;0.0077	0.9546;0.0074;0.0303;0.0077	0.9546;0.0074;0.0303;0.0077
alt_YEE_rec_4K_12	chr10	52600	479	A1;	A2;	B3;	B4	1;2;3;4	4	0.9528;0.0083;0.0316;0.0073	0.9528;0.0083;0.0316;0.0073	0.9528;0.0083;0.0316;0.0073
alt_YEE_rec_4K_12	chr10	53600	494	A1;	A2;	B3;	B4	1;2;3;4	4	0.951;0.009;0.0329;0.0071	0.951;0.009;0.0329;0.0071	0.951;0.009;0.0329;0.0071
alt_YEE_rec_4K_12	chr10	54600	507	A1;	A2;	B3;	B4	1;2;3;4	4	0.9494;0.0093;0.0339;0.0074	0.9494;0.0093;0.0339;0.0074	0.9494;0.0093;0.0339;0.0074
alt_YEE_rec_4K_12	chr10	55600	520	A1;	A2;	B3;	B4	1;2;3;4	4	0.9481;0.0092;0.0342;0.0085	0.9481;0.0092;0.0342;0.0085	0.9481;0.0092;0.0342;0.0085
alt_YEE_rec_4K_12	chr10	56600	545	A1;	A2;	B3;	B4	1;2;3;4	4	0.9472;0.0087;0.0335;0.0106	0.9472;0.0087;0.0335;0.0106	0.9472;0.0087;0.0335;0.0106
alt_YEE_rec_4K_12	chr10	57600	561	A1;	A2;	B3;	B4	1;2;3;4	4	0.9472;0.0081;0.0313;0.0134	0.9472;0.0081;0.0313;0.0134	0.9472;0.0081;0.0313;0.0134
alt_YEE_rec_4K_12	chr10	58600	577	A1;	A2;	B3;	B4	1;2;3;4	4	0.9482;0.0076;0.0283;0.0158	0.9482;0.0076;0.0283;0.0158	0.9482;0.0076;0.0283;0.0158
alt_YEE_rec_4K_12	chr10	59600	592	A1;	A2;	B3;	B4	1;2;3;4	4	0.9497;0.007;0.0257;0.0176	0.9497;0.007;0.0257;0.0176	0.9497;0.007;0.0257;0.0176
alt_YEE_rec_4K_12	chr10	60600	606	A1;	A2;	B3;	B4	1;2;3;4	4	0.9515;0.006;0.0234;0.019	0.9515;0.006;0.0234;0.019	0.9515;0.006;0.0234;0.019
alt_YEE_rec_4K_12	chr10	61600	615	A1;	A2;	B3;	B4	1;2;3;4	4	0.9532;0.0047;0.0217;0.0204	0.9532;0.0047;0.0217;0.0204	0.9532;0.0047;0.0217;0.0204
alt_YEE_rec_4K_12	chr10	62600	617	A1;	A2;	B3;	B4	1;2;3;4	4	0.9543;0.003;0.0204;0.0222	0.9543;0.003;0.0204;0.0222	0.9543;0.003;0.0204;0.0222
alt_YEE_rec_4K_12	chr10	63600	625	A1;	A2;	B3;	B4	1;2;3;4	4	0.9541;0.001;0.0197;0.0252	0.9541;0.001;0.0197;0.0252	0.9541;0.001;0.0197;0.0252
alt_YEE_rec_4K_12	chr10	64600	629	A1;	A2;	B3;	B4	1;2;3;4	4	0.9503;3e-04;0.0184;0.0309	0.9503;3e-04;0.0184;0.0309	0.9503;3e-04;0.0184;0.0309
alt_YEE_rec_4K_12	chr10	65600	626	A1;	A2;	B3;	B4	1;2;3;4	4	0.9382;3e-04;0.0147;0.0468	0.9382;3e-04;0.0147;0.0468	0.9382;3e-04;0.0147;0.0468
alt_YEE_rec_4K_12	chr10	66600	611	A1;	A2;	B3;	B4	1;2;3;4	4	0.9149;3e-04;0.0066;0.0781	0.9149;3e-04;0.0066;0.0781	0.9149;3e-04;0.0066;0.0781
alt_YEE_rec_4K_12	chr10	67600	627	A1;	A2;	B3;	B4	1;2;3;4	4	0.8752;3e-04;3e-04;0.1242	0.8752;3e-04;3e-04;0.1242	0.8752;3e-04;3e-04;0.1242
alt_YEE_rec_4K_12	chr10	68600	620	A1;	A2;	B3;	B4	1;2;3;4	4	0.8128;3e-04;3e-04;0.1866	0.8128;3e-04;3e-04;0.1866	0.8128;3e-04;3e-04;0.1866
alt_YEE_rec_4K_12	chr10	69600	619	A1;	A2;	B3;	B4	1;2;3;4	4	0.7215;3e-04;3e-04;0.2779	0.7215;3e-04;3e-04;0.2779	0.7215;3e-04;3e-04;0.2779
alt_YEE_rec_4K_12	chr10	70600	624	A1;	A2;	B3;	B4	1;2;3;4	4	0.589;3e-04;3e-04;0.4104	0.589;3e-04;3e-04;0.4104	0.589;3e-04;3e-04;0.4104
alt_YEE_rec_4K_12	chr10	71600	626	A1;	A2;	B3;	B4	1;2;3;4	4	0.431;3e-04;3e-04;0.5684	0.431;3e-04;3e-04;0.5684	0.431;3e-04;3e-04;0.5684
alt_YEE_rec_4K_12	chr10	72600	628	A1;	A2;	B3;	B4	1;2;3;4	4	0.2769;3e-04;3e-04;0.7225	0.2769;3e-04;3e-04;0.7225	0.2769;3e-04;3e-04;0.7225
alt_YEE_rec_4K_12	chr10	73600	618	A1;	A2;	B3;	B4	1;2;3;4	4	0.1519;0.0103;3e-04;0.8376	0.1519;0.0103;3e-04;0.8376	0.1519;0.0103;3e-04;0.8376
alt_YEE_rec_4K_12	chr10	74600	615	A1;	A2;	B3;	B4	1;2;3;4	4	0.0731;0.0144;0.0088;0.9037	0.0731;0.0144;0.0088;0.9037	0.0731;0.0144;0.0088;0.9037
alt_YEE_rec_4K_12	chr10	75600	618	A1;	A2;	B3;	B4	1;2;3;4	4	0.0307;0.0124;0.0166;0.9403	0.0307;0.0124;0.0166;0.9403	0.0307;0.0124;0.0166;0.9403
alt_YEE_rec_4K_12	chr10	76600	615	A1;	A2;	B3;	B4	1;2;3;4	4	0.0121;0.0092;0.0186;0.96	0.0121;0.0092;0.0186;0.96	0.0121;0.0092;0.0186;0.96
alt_YEE_rec_4K_12	chr10	77600	625	A1;	A2;	B3;	B4	1;2;3;4	4	0.0071;0.0068;0.0184;0.9677	0.0071;0.0068;0.0184;0.9677	0.0071;0.0068;0.0184;0.9677
alt_YEE_rec_4K_12	chr10	78600	628	A1;	A2;	B3;	B4	1;2;3;4	4	0.0072;0.0048;0.0186;0.9694	0.0072;0.0048;0.0186;0.9694	0.0072;0.0048;0.0186;0.9694
alt_YEE_rec_4K_12	chr10	79600	630	A1;	A2;	B3;	B4	1;2;3;4	4	0.0076;0.0028;0.0178;0.9717	0.0076;0.0028;0.0178;0.9717	0.0076;0.0028;0.0178;0.9717
alt_YEE_rec_4K_12	chr10	80600	631	A1;	A2;	B3;	B4	1;2;3;4	4	0.0073;0.0014;0.0154;0.9759	0.0073;0.0014;0.0154;0.9759	0.0073;0.0014;0.0154;0.9759
alt_YEE_rec_4K_12	chr10	81600	633	A1;	A2;	B3;	B4	1;2;3;4	4	0.0059;4e-04;0.0119;0.9817	0.0059;4e-04;0.0119;0.9817	0.0059;4e-04;0.0119;0.9817
alt_YEE_rec_4K_12	chr10	82600	635	A1;	A2;	B3;	B4	1;2;3;4	4	0.004;3e-04;0.0096;0.9861	0.004;3e-04;0.0096;0.9861	0.004;3e-04;0.0096;0.9861
alt_YEE_rec_4K_12	chr10	83600	635	A1;	A2;	B3;	B4	1;2;3;4	4	0.0029;3e-04;0.0108;0.9859	0.0029;3e-04;0.0108;0.9859	0.0029;3e-04;0.0108;0.9859
alt_YEE_rec_4K_12	chr10	84600	644	A1;	A2;	B3;	B4	1;2;3;4	4	0.0031;3e-04;0.0155;0.9811	0.0031;3e-04;0.0155;0.9811	0.0031;3e-04;0.0155;0.9811
alt_YEE_rec_4K_12	chr10	85600	637	A1;	A2;	B3;	B4	1;2;3;4	4	0.0034;3e-04;0.02;0.9763	0.0034;3e-04;0.02;0.9763	0.0034;3e-04;0.02;0.9763
alt_YEE_rec_4K_12	chr10	86600	654	A1;	A2;	B3;	B4	1;2;3;4	4	0.0035;3e-04;0.0219;0.9743	0.0035;3e-04;0.0219;0.9743	0.0035;3e-04;0.0219;0.9743
alt_YEE_rec_4K_12	chr10	87600	661	A1;	A2;	B3;	B4	1;2;3;4	4	0.0037;3e-04;0.0196;0.9765	0.0037;3e-04;0.0196;0.9765	0.0037;3e-04;0.0196;0.9765
alt_YEE_rec_4K_12	chr10	88600	662	A1;	A2;	B3;	B4	1;2;3;4	4	0.0039;3e-04;0.0136;0.9822	0.0039;3e-04;0.0136;0.9822	0.0039;3e-04;0.0136;0.9822
alt_YEE_rec_4K_12	chr10	89600	674	A1;	A2;	B3;	B4	1;2;3;4	4	0.0038;3e-04;0.0091;0.9867	0.0038;3e-04;0.0091;0.9867	0.0038;3e-04;0.0091;0.9867
alt_YEE_rec_4K_12	chr10	90600	671	A1;	A2;	B3;	B4	1;2;3;4	4	0.0037;3e-04;0.0077;0.9884	0.0037;3e-04;0.0077;0.9884	0.0037;3e-04;0.0077;0.9884
alt_YEE_rec_4K_12	chr10	91600	675	A1;	A2;	B3;	B4	1;2;3;4	4	0.0037;3e-04;0.0097;0.9862	0.0037;3e-04;0.0097;0.9862	0.0037;3e-04;0.0097;0.9862
alt_YEE_rec_4K_12	chr10	92600	676	A1;	A2;	B3;	B4	1;2;3;4	4	0.0039;0.0014;0.015;0.9798	0.0039;0.0014;0.015;0.9798	0.0039;0.0014;0.015;0.9798
alt_YEE_rec_4K_12	chr10	93600	694	A1;	A2;	B3;	B4	1;2;3;4	4	0.004;0.0027;0.0211;0.9722	0.004;0.0027;0.0211;0.9722	0.004;0.0027;0.0211;0.9722

Figure 27 Exemple d'un fichier utilisé pour le projet de biostats

Dans le cadre de ma formation en **BUT Science des Données**, j'ai effectué un stage de douze semaines au sein du département de statistiques appliquées de la **Johannes Kepler Universität de Linz**, en Autriche. Ce rapport rend compte de l'ensemble des travaux réalisés, ainsi que des compétences techniques, scientifiques et humaines que j'ai pu développer au cours de cette expérience.

J'ai d'abord participé à un projet de **prévision de la consommation électrique** pour la **Linz AG**, dans le cadre d'un concours universitaire. Ce travail m'a conduit à manipuler des données énergétiques et météorologiques à haute fréquence, à mener des analyses exploratoires, et à construire des modèles prédictifs en R et Python, en utilisant des méthodes avancées comme Random Forest et XGBoost.

En parallèle, j'ai été impliqué dans un projet de **biostatistique** visant à reproduire des résultats graphiques issus d'une étude scientifique sur l'évolution génétique de levures. Ce second volet m'a permis d'approfondir mes connaissances en génétique statistique et en visualisation de données, tout en développant mon autonomie face à des publications scientifiques complexes.

Ce stage a également représenté une véritable immersion linguistique et culturelle, renforçant mes capacités d'adaptation, ma rigueur scientifique et mon ouverture à l'international. Il constitue une étape déterminante dans mon parcours, confirmant mon souhait de poursuivre vers un master en data science.